

BỘ GIÁO DỤC VÀ ĐÀO TẠO



HUTECH
Đại học Công nghệ Tp.HCM

ĐỀ CƯƠNG LUẬN VĂN THẠC SỸ

Chuyên ngành: Công nghệ thông tin

Mã ngành: 2241860026

**NGHIÊN CỨU VÀ PHÁT TRIỂN MÔ HÌNH HỌC SÂU CHO
BÀI TOÁN PHÂN LOẠI CHẤT LƯỢNG TỎI**

GVHD: TS. LÊ CUNG TƯỜNG
HVTH: HOÀNG TRẦN GIA PHÚC
MSHV: 2341861010
Lớp : 23SCT31

TP.HCM, tháng 10/2025

This image shows a full page of white paper with horizontal dotted lines. The lines are evenly spaced and run across the width of the page, providing a guide for handwriting practice. There are no margins, text, or other markings on the page.

Giáo viên hướng dẫn

NHẬN XÉT CỦA HỘI ĐỒNG XÉT DUYỆT

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Tp.HCM, ngày tháng năm 2025

Hội đồng xét duyệt

MỤC LỤC

DANH MỤC CÁC BẢNG.....	5
DANH MỤC CÁC HÌNH	5
1. GIỚI THIỆU	6
1.1 Đặt vấn đề.....	6
1.2 Tính cấp thiết của đề tài.....	6
2. MỤC TIÊU, NỘI DUNG VÀ PHƯƠNG PHÁP NGHIÊN CỨU	8
2.1 Mục tiêu của đề tài	8
2.2 Nội dung nghiên cứu	9
2.3 Phương pháp luận và phương pháp nghiên cứu	14
3. TỔNG QUAN VỀ LĨNH VỰC NGHIÊN CỨU	16
3.1 Các phương pháp phát hiện và phân loại nông sản sau thu hoạch	16
3.2 Các nghiên cứu liên quan	17
3.3 Các kỹ thuật chính được sử dụng	18
4. TIẾN ĐỘ THỰC HIỆN	19
5. BỐ CỤC DỰ KIẾN CỦA LUẬN VĂN.....	20
6. TÀI LIỆU THAM KHẢO	22

DANH MỤC CÁC BẢNG

Bảng 1: Mô tả bộ dữ liệu.....	10
Bảng 2: Tiến độ thực hiện của đề tài.....	19

DANH MỤC CÁC HÌNH

Hình 1: Quy trình tổng thể phát triển hệ thống phân loại tội.....	11
Hình 2: Phân bố các lớp trong bộ dữ liệu.....	15

1. GIỚI THIỆU

1.1 Đặt vấn đề

Nông nghiệp từ lâu đã là một trụ cột không thể thiếu trong nền kinh tế Việt Nam. Theo số liệu thống kê năm 2025, khu vực nông, lâm nghiệp và thủy sản chiếm tỷ trọng **11,64%** trong cơ cấu nền kinh tế [1]. Mặc dù chịu tác động của thiên tai, ngành vẫn duy trì đà tăng trưởng ổn định, đảm bảo an ninh lương thực và giải quyết việc làm cho một bộ phận lớn lao động trên cả nước. Trong lĩnh vực nông nghiệp, hoạt động sản xuất và chế biến nông sản giữ vai trò then chốt trong chuỗi cung ứng, đặc biệt là các *sản phẩm chế biến từ tỏi* – một thành phần thiết yếu trong nhiều ứng dụng ẩm thực và công nghiệp thực phẩm.

Quy trình sản xuất sản phẩm chế biến từ tỏi thường trải qua các giai đoạn như tách tỏi thành từng tép, loại bỏ vỏ, làm sạch và tiến hành chế biến. Hiện nay, nhờ sự hỗ trợ của máy móc, các công đoạn tách tép và bóc vỏ đã được cải thiện đáng kể về mặt năng suất. Tuy nhiên, sau khi qua máy bóc vỏ, việc phân loại tỏi thành các nhóm như tỏi sạch, tỏi hư và tỏi còn sót vỏ vẫn phải thực hiện bằng tay. Công đoạn này đòi hỏi người lao động có kỹ năng, tốn nhiều thời gian và dễ xảy ra nhầm lẫn, từ đó ảnh hưởng đến chất lượng của sản phẩm cuối cùng.

Sự tiến bộ của trí tuệ nhân tạo (AI) cùng với công nghệ học sâu (Deep Learning) đã mở ra tiềm năng lớn trong việc tự động hóa các khâu xử lý nông sản. Các mô hình học sâu có khả năng phân tích hình ảnh của tỏi sau khi bóc vỏ, từ đó phân loại chính xác thành ba nhóm kể trên, vượt trội hơn so với cách làm thủ công truyền thống.

Nghiên cứu tập trung **phát triển mô hình học sâu** cho bài toán phân loại chất lượng tỏi trong dây chuyền sản xuất thực phẩm. Hệ thống được thiết kế để tự động thu nhận dữ liệu hình ảnh, huấn luyện mô hình phân loại ba nhóm (tỏi sạch, tỏi còn vỏ, tỏi hư) và đưa ra kết quả phân loại với độ chính xác đáp ứng yêu cầu công nghiệp, góp phần giảm phụ thuộc lao động thủ công và nâng cao độ ổn định chất lượng sản phẩm.

1.2 Tính cấp thiết của đề tài

Luận văn “*Nghiên cứu và phát triển mô hình học sâu cho bài toán phân loại chất lượng tỏi*” được xây dựng dựa trên những lý do sau:

1.2.1 Tự động hóa quy trình phân loại tỏi

Hiện nay, sau khi qua công đoạn bóc vỏ bằng máy, tỏi vẫn phải trải qua quá trình phân loại thủ công để phân thành các nhóm: tỏi sạch, tỏi hư và tỏi còn sót vỏ. Phương pháp này không chỉ tiêu tốn nhiều thời gian mà còn đòi hỏi lượng lớn nhân công, gây áp lực lên chi phí sản xuất. Việc triển khai một hệ thống phân loại tự động sẽ thay thế hoàn toàn công đoạn thủ công, giúp tối ưu hóa quy trình, giảm thiểu sự phụ thuộc vào lao động tay chân và tăng tốc độ xử lý trong dây chuyền chế biến.

1.2.2 Nâng cao năng suất và chất lượng sản phẩm

Phân loại thủ công thường không đảm bảo tính nhất quán do sai sót từ yếu tố con người, chẳng hạn như việc tỏi hư hoặc tỏi còn vỏ bị lẫn vào nhóm tỏi sạch. Điều này ảnh hưởng trực tiếp đến chất lượng của các sản phẩm chế biến từ tỏi, làm giảm giá trị thương mại và uy tín của doanh nghiệp. Hệ thống ứng dụng trí tuệ nhân tạo (AI) trong luận văn này đảm bảo độ chính xác cao trong việc nhận diện và phân loại, từ đó mang lại sản phẩm đồng nhất về chất lượng, đồng thời nâng cao hiệu suất chế biến để đáp ứng nhu cầu thị trường.

1.2.3 Ứng dụng công nghệ Deep Learning trong nông nghiệp

Công nghệ học sâu (Deep Learning) nổi bật với khả năng phân tích hình ảnh vượt trội, cho phép nhận diện nhanh chóng và chính xác các đặc điểm của tỏi như màu sắc, kích thước hay khuyết tật. Hệ thống này không chỉ thực hiện phân loại hiệu quả mà còn có khả năng tự học hỏi và cải thiện qua thời gian nhờ dữ liệu huấn luyện. Điều này giúp hệ thống linh hoạt, dễ dàng thích nghi với các loại tỏi khác nhau hoặc điều kiện sản xuất đa dạng, mở ra tiềm năng ứng dụng rộng rãi trong ngành nông nghiệp.

1.2.4 Giảm chi phí lao động và tăng hiệu quả kinh tế

Theo khảo sát, việc phân loại thủ công tốn trung bình 2–3 nhân công cho 1 dây chuyền nhỏ, trong khi hệ thống AI có thể thay thế toàn bộ với chi phí điện năng thấp hơn 40%

Tự động hóa khâu phân loại tỏi giúp giảm đáng kể số lượng nhân công cần thiết, từ đó cắt giảm chi phí vận hành cho doanh nghiệp. Hơn nữa, hệ thống hoạt động ổn định và liên tục, đảm bảo sản lượng cao mà không bị gián đoạn bởi các yếu tố như mệt mỏi hay thiếu hụt lao động. Kết quả là doanh nghiệp không chỉ tiết kiệm chi phí mà còn nâng

cao tính cạnh tranh trên thị trường, tối ưu hóa lợi nhuận và tạo nền tảng phát triển bền vững.

1.2.5 Định hướng phát triển nền nông nghiệp thông minh

Việc ứng dụng AI trong phân loại nông sản là một bước tiến quan trọng, phù hợp với xu hướng hiện đại hóa ngành chế biến thực phẩm và nông nghiệp công nghệ cao. Luận văn này không chỉ mang lại giải pháp thiết thực cho việc sản xuất các sản phẩm chế biến từ tỏi mà còn đặt nền móng cho việc mở rộng ứng dụng sang các loại nông sản khác như hành, gừng hay khoai tây trong tương lai. Qua đó, nghiên cứu góp phần thúc đẩy sự phát triển của một nền nông nghiệp thông minh, bền vững và hiệu quả tại Việt Nam.

2. MỤC TIÊU, NỘI DUNG VÀ PHƯƠNG PHÁP NGHIÊN CỨU

Đối tượng nghiên cứu: Hình ảnh và đặc điểm của tỏi sau khi bóc vỏ trong dây chuyền chế biến thực phẩm, bao gồm ba nhóm: tỏi sạch (đã bóc vỏ hoàn toàn, không hư hỏng), tỏi hư (thối rửa hoặc đổi màu), và tỏi còn vỏ (chưa bóc sạch lớp vỏ).

Phạm vi nghiên cứu:

- Phạm vi không gian: Thực hiện tại một xưởng chế biến tỏi quy mô nhỏ hoặc trung bình tại Việt Nam, tập trung vào hệ thống phân loại tự động đơn giản.
- Phạm vi thời gian: Nghiên cứu được tiến hành trong khoảng 6 tháng, bao gồm các giai đoạn thu thập dữ liệu, phát triển mô hình, và thử nghiệm hệ thống.

2.1 Mục tiêu của đề tài

2.1.1 Mục tiêu tổng quát

Nghiên cứu và phát triển một mô hình học sâu có độ chính xác cao và hiệu quả để tự động phân loại chất lượng tỏi trong môi trường sản xuất công nghiệp. Mô hình sẽ phân loại tỏi thành ba nhóm chính: **tỏi sạch** (đã bóc vỏ hoàn toàn, không hư hỏng), **tỏi hư** (thối rửa hoặc đổi màu), và **tỏi còn vỏ**

(chưa bóc sạch lớp vỏ).

2.1.2 Mục tiêu cụ thể

- Thu thập bộ dữ liệu dự kiến khoảng 3000 hình ảnh thực tế của tỏi tại xưởng chế biến bằng thiết bị di động thông minh để xây dựng bộ dữ liệu huấn luyện mô hình học sâu. Quá trình thu thập ảnh sẽ được chuẩn hóa về điều kiện ánh sáng và góc

chụp để đảm bảo tính nhất quán cho bộ dữ liệu, giảm thiểu các yếu tố gây nhiễu từ môi trường.

- Thực nghiệm các mô hình: ResNet50, VGG16, MobileNetV2, EfficientNet-B0, và InceptionV3, Vision Transformer (ViT) và Swin Transformer (Swin-T) trên bộ dữ liệu đã thu thập với dự kiến khoảng 3000 ảnh thực tế được chụp từ xưởng sản xuất. Bộ dữ liệu này cung cấp hình ảnh về tòi sau khi được xử lý qua máy tách vỏ, được phân loại với ba nhóm: tòi sạch (đã bóc vỏ hoàn toàn, không hư hỏng), tòi hư (thối rửa hoặc đổi màu), và tòi còn vỏ (chưa bóc sạch lớp vỏ).
- Lựa chọn mô hình có kết quả tốt nhất để tiếp tục kết hợp với một số phương pháp tập trung vào đặc điểm nổi bật (Attention) như: SE (Squeeze-and-Excitation), CBAM (Convolutional Block Attention Module), ACE (Attention-based Convolutional Enhancement), SimAM (Simple Attention Module) và Coordinate Attention (CoordAtt) nhằm cải thiện hiệu suất của bài toán dựa trên các chỉ số đánh giá bao gồm: Độ chính xác (Accuracy), Độ chính xác từng lớp (Precision), Độ thu hồi (Recall) và Điểm F1 (F1-score).
- Cuối cùng, đề xuất mô hình học sâu hiệu quả nhất cho bài toán.

2.2 Nội dung nghiên cứu

2.2.1 Tìm hiểu các đặc điểm phân loại tòi trong chế biến thực phẩm

Tìm hiểu đặc điểm hình ảnh của tòi sau khi bóc vỏ: tòi sạch, tòi hư và tòi còn vỏ, làm cơ sở cho việc phân loại trên dây chuyền chế biến.

Xem xét các yếu tố ảnh hưởng chất lượng tòi, từ môi trường xưởng đến quy trình bóc vỏ và lỗi thủ công thường gặp.

Dự kiến số lượng ảnh của lớp “tòi sạch” sẽ chiếm đa số, trong khi lớp “tòi hư” và “tòi còn vỏ” có thể ít hơn. Vấn đề mất cân bằng dữ liệu tiềm tàng này sẽ được xử lý trong quá trình huấn luyện mô hình.

2.2.2 Phân tích và thu thập dữ liệu hình ảnh

Thu thập dự kiến khoảng 3000 ảnh thực tế của tòi tại xưởng bằng thiết bị di động thông minh, ảnh chất lượng cao từ thiết bị di động. Độ phân giải 4032x 3024 pixels và chia thành ba nhóm: tòi sạch, tòi hư, tòi còn vỏ.

2.2.3 Tiền xử lý ảnh

Bộ ảnh được phân loại thủ công bởi các công nhân có kinh nghiệm thành ba nhãn: ***clean_garlic***, ***partially_peeled_garlic***, ***rotten_garlic***. Mỗi mẫu được chụp ít nhất 2–3 ảnh sau đó ảnh gốc được lưu ảnh với chất lượng cao từ thiết bị di động.


Chuyển đổi về định dạng chuẩn (JPG/PNG) để huấn luyện. Chuẩn hóa kích thước (224 x 224 pixels), tăng cường độ nét và gắn nhãn dữ liệu.

Bảng 1: Mô tả bộ dữ liệu

Tên nhãn	Mô tả	Ảnh minh họa
Tỏi sạch (<i>clean_garlic</i>)	Các tép tỏi có bề mặt nhẵn mịn và đồng nhất, không còn sót vỏ lụa hay xuất hiện các khuyết tật bề mặt có thể quan sát bằng mắt thường. Đây là nhóm đạt tiêu chuẩn để đóng gói, đưa vào chế biến công nghiệp hoặc sử dụng trực tiếp	
Tỏi hư (<i>rotten_garlic</i>)	Các tép tỏi biểu hiện các khuyết tật rõ rệt như biến đổi màu sắc (thâm đen, úa vàng), nấm mốc, bị nhũn hoặc dập nát bề mặt. Nhóm này bị loại bỏ hoàn toàn khỏi dây chuyền chế biến và không còn giá trị sử dụng nhằm đảm bảo các yêu cầu về an toàn vệ sinh thực phẩm.	
Tỏi còn vỏ (<i>partially_peeled_garlic</i>)	Các tép tỏi vẫn còn một phần vỏ lụa bám trên bề mặt. Nhóm này thường được tách riêng để đưa qua công đoạn làm sạch bổ sung (tái chế biến) trước khi được phân loại là tỏi sạch vỏ.	

2.2.4 Phát triển và huấn luyện mô hình học sâu

Quy trình nghiên cứu được chia thành hai giai đoạn chính: (1) Huấn luyện và đánh giá các mô hình nền tảng để tìm ra kiến trúc tối ưu nhất; (2) Cải tiến mô hình tốt nhất bằng cách tích hợp các cơ chế chú ý (attention) nâng cao.



Hình 1: Quy trình tổng thể phát triển hệ thống phân loại tối.

2.2.4.1 Giai đoạn 1 lựa chọn mô hình nền tảng

Tiến hành thực nghiệm trên các mô hình học chuyển giao (Transfer Learning) phổ biến và hiện đại:

- **Kiến trúc CNN:** ResNet50, VGG16, MobileNetV2, EfficientNet-B0, InceptionV3.
- **Kiến trúc Transformer:** Vision Transformer (ViT) và Swin Transformer (Swin-T).

Mặc dù sự phân bố dữ liệu giữa các tập huấn luyện, xác thực và kiểm tra được đảm bảo tính nhất quán, song thực tế vẫn tồn tại sự mất cân bằng nhẹ khi số lượng mẫu của lớp “tối hư” chiếm tỷ trọng lớn hơn các lớp còn lại. Để hạn chế xu hướng mô hình thiên lệch về phía lớp đa số, đề tài áp dụng đồng bộ các chiến lược xử lý hiệu quả sau:

- **Tăng cường dữ liệu (Data Augmentation):** Thực hiện các phép biến đổi ngẫu nhiên về hình học và không gian màu trên tập huấn luyện (như xoay, phóng to/thu nhỏ, dịch chuyển, cắt xén, lật ảnh, điều chỉnh độ sáng/tương phản). Kỹ thuật này

không chỉ làm phong phú dữ liệu mà còn mô phỏng các biến thiên của môi trường thực tế, giúp mô hình học được các đặc trưng bất biến (invariant features) của đối tượng.

- **Chiến lược Định hướng Recall (Recall-Oriented Strategy):** Với mục tiêu cốt lõi là giảm thiểu tối đa việc bỏ sót lỗi, đề tài triển khai các kỹ thuật chuyên sâu:
 - **Cost-Sensitive Learning (Học dựa trên chi phí):** Thiết lập ma trận trọng số trong hàm mất mát, áp dụng mức phạt (penalty) cao hơn đối với các trường hợp dự đoán sai lớp "Tối hu" (False Negative) so với các sai sót khác. Cơ chế này buộc mô hình phải ưu tiên học kỹ hơn các đặc trưng của lớp tối hu.
 - **Focal Loss:** Thay thế hàm mất mát truyền thống bằng Focal Loss nhằm tập trung sự chú ý vào các mẫu khó phân loại (hard examples). Điều này đặc biệt hiệu quả với các trường hợp tối hu nhẹ có đặc điểm hình thái gần giống với tối còn vỏ, giúp cải thiện độ chính xác tại vùng biên quyết định (decision boundary).
- **Học chuyển giao và Tinh chỉnh (Transfer Learning with Fine-Tuning):** Tập dụng trọng số đã được huấn luyện trước trên các tập dữ liệu lớn. Toàn bộ mô hình nền sẽ được “freeze”, “unfreeze” N block/layers tương ứng để tinh chỉnh. Cách tiếp cận này giúp bảo toàn các đặc trưng tổng quát đã học và chỉ tập trung cập nhật các đặc trưng cấp cao, đặc thù của bài toán phân loại tối.
- **Chống quá khớp (Regularization):** Sử dụng kỹ thuật Dropout với tỷ lệ 0.4 và 0.5 tại các lớp kết nối đầy đủ để ngăn chặn hiện tượng học quá khớp (overfitting).
- **Tối ưu hóa tốc độ học (Learning Rate Scheduling):** Áp dụng Cosine Decay để điều chỉnh tốc độ học một cách linh hoạt trong suốt quá trình huấn luyện, giúp mô hình hội tụ tốt hơn.
- **Điều kiện dừng sớm (Early Stopping & Model Checkpointing):** Sử dụng EarlyStopping theo validation loss; đồng thời lưu checkpoint theo metric ‘best weighted F1’

2.2.4.2 Giai đoạn 2 tối ưu hóa kiến trúc với cơ chế Attention và Hybrid Learning

Dựa trên kết quả thực nghiệm Giai đoạn 1, mô hình nền tảng có hiệu năng tốt nhất (đánh giá qua **Weighted F1-score** và ưu tiên **Recall** cho lớp ‘tỏi hư’ trên tập validation) sẽ được lựa chọn để tiếp tục cải tiến. Quá trình tối ưu hóa ở giai đoạn này được chia thành hai bước tiếp cận chuyên sâu:

Bước 1: Tích hợp cơ chế Attention đơn lẻ (Single Attention Integration) Các module Attention hiện đại sẽ được chèn vào các vị trí chiến lược trong kiến trúc mô hình nền (backbone) nhằm tăng cường khả năng tập trung vào các đặc trưng quan trọng và loại bỏ nhiễu nền. Các cơ chế được thử nghiệm bao gồm:

- **SE (Squeeze-and-Excitation):** Tối ưu hóa trọng số giữa các kênh đặc trưng.
- **CBAM (Convolutional Block Attention Module):** Kết hợp chú ý cả về không gian (spatial) và kênh (channel).
- **SimAM (Simple, Parameter-Free Attention Module):** Cơ chế chú ý không tham số dựa trên năng lượng.
- **CoordAtt (Coordinate Attention):** Tăng cường khả năng định vị đặc trưng theo tọa độ.
- **ACE (Attention-based Convolutional Enhancement):** Cải thiện các lớp tích chập truyền thống.

Bước 2: Thử nghiệm kiến trúc lai ghép (Hybrid Architecture) với Dual Attention Fusion để giải quyết triệt để các hạn chế của mô hình đơn lẻ, đề tài đề xuất áp dụng phương pháp **Dual Attention Fusion**. Đây là kiến trúc lai ghép hoạt động trên cơ chế hai nhánh song song nhằm tổng hợp đa dạng thông tin:

- **Nhánh Local Attention (CNN-based):** Sử dụng các block nhẹ (như ECA hoặc CBAM-lite) để trích xuất đặc trưng mức độ vân bề mặt (texture-level). Nhánh này chuyên biệt cho việc phát hiện các chi tiết hư hỏng nhỏ cục bộ như vết nám mốc, vết xước hoặc đốm đen trên vỏ tỏi.
- **Nhánh Global Attention (Transformer-based):** Sử dụng các khối Swin Block hoặc Windowed MSA để học mối quan hệ ngữ cảnh toàn cục giữa các vùng ảnh. Nhánh này giúp mô hình nhận diện các biến dạng hình học tổng thể (ví dụ: củ tỏi bị teo tóp, méo mó).

Hai luồng đặc trưng (Local và Global) sau đó sẽ được hợp nhất (Fusion) để đưa ra dự đoán cuối cùng với độ tin cậy cao nhất.

Kết quả kỳ vọng: Sản phẩm cuối cùng của đề tài là một mô hình học sâu hoàn chỉnh, đã được tối ưu hóa sâu về kiến trúc (thông qua Hybrid Learning) và kỹ thuật huấn luyện. Mô hình đảm bảo khả năng phân loại chính xác chất lượng tối, giảm thiểu tỷ lệ bỏ sót tối hư, đồng thời đáp ứng yêu cầu về tốc độ xử lý để triển khai trong môi trường công nghiệp thực tế.

2.2.5 Đánh giá và tối ưu hóa hệ thống

Đánh giá hiệu suất mô hình sẽ sử dụng các chỉ số: Độ chính xác (Accuracy), Độ chính xác từng lớp (Precision), Độ thu hồi (Recall) và Điểm F1 (F1-score). Việc lựa chọn mô hình tối ưu dựa trên **weighted F1-score** trên tập validation; đồng thời ưu tiên tăng Recall cho lớp “tối hư” nhằm giảm thiểu bỏ sót sản phẩm không đạt chất lượng

Thử nghiệm thực tế: Sử dụng dữ liệu thực tế, so sánh với phương pháp thủ công để làm rõ ưu điểm, tập trung vào tốc độ phân loại và tỷ lệ lỗi để đánh giá toàn diện.

Tối ưu hóa: Điều chỉnh mô hình học sâu (như tinh chỉnh tham số hoặc giảm độ phức tạp) dựa trên kết quả thực tế, đảm bảo hệ thống hoạt động ổn định.

2.3 Phương pháp luận và phương pháp nghiên cứu

2.3.1 Phương pháp luận

Phương pháp hệ thống: Tiếp cận vấn đề phân loại tối như một hệ thống toàn diện, kết hợp giữa công nghệ học sâu (Deep Learning) và quy trình xử lý thực tế trong sản xuất nông sản. Quá trình này bao gồm các giai đoạn: thu thập dữ liệu hình ảnh thực tế từ xưởng chế biến, tiền xử lý và gán nhãn dữ liệu, phát triển mô hình phân loại sử dụng các kiến trúc mạng CNN, và cuối cùng là triển khai hệ thống nhận diện tự động vào quy trình phân loại. Cách tiếp cận này đảm bảo tính ứng dụng cao, khả năng mở rộng và độ chính xác trong môi trường vận hành thực tế.

Phương pháp thực nghiệm: Áp dụng phương pháp thử nghiệm thực tiễn để xây dựng, đánh giá và hoàn thiện mô hình phân loại tối. Thông qua các lần huấn luyện và kiểm thử với nhiều kiến trúc mạng học sâu khác nhau (ResNet50, VGG16, MobileNetV2, EfficientNet-B0, và InceptionV3, Vision Transformer (ViT) và Swin Transformer (Swin-T)), hệ thống được điều chỉnh linh hoạt dựa trên kết quả thu được

nhằm tối ưu hóa độ chính xác và hiệu suất nhận diện, phù hợp với điều kiện sản xuất cụ thể tại xưởng chế biến tỏi.

2.3.2 Phương pháp nghiên cứu


2.3.2.1 Phương pháp thu thập dữ liệu

Thu thập dữ liệu khoảng 3000 hình ảnh thực tế của tỏi sau khi bóc vỏ tại xưởng chế biến sử dụng camera sử dụng thiết bị di động thông minh có camera độ phân giải cao. Bộ dữ liệu được xây dựng bao gồm ba nhóm chính: tỏi sạch, tỏi hư, và tỏi còn vỏ tạo nền tảng phong phú và đa dạng cho việc huấn luyện mô hình học sâu.

2.3.2.2 Phương pháp xử lý ảnh

Tiền xử lý ảnh đầu vào như chuyển đổi định dạng, xóa nền, cắt và chuẩn hóa trước khi huấn luyện.

Chia bộ dữ liệu ra làm 3 tập dữ liệu Training, Test, Validation với tỷ lệ lần lượt là **70-15-15**.



Hình 2: Phân bố các lớp trong bộ dữ liệu

2.3.2.3 Phương pháp phát triển mô hình học sâu

Tìm kiếm và lựa chọn mô hình CNN phù hợp bằng cách chạy thực nghiệm trên các mô hình Transfer Learning tiên tiến nhất hiện nay (ResNet50, VGG16, MobileNetV2,

EfficientNet-B0, và InceptionV3, Vision Transformer (ViT) và Swin Transformer (Swin-T)) với bộ dữ liệu dự kiến khoảng 3000 ảnh đã thu thập.

Đánh giá hiệu quả của từng mô hình dựa trên độ chính xác, tốc độ xử lý và khả năng phân loại ba nhóm tỏi (tỏi sạch, tỏi hư, tỏi còn vỏ), từ đó chọn ra mô hình hoạt động tốt nhất với dataset này.

Tối ưu mô hình đã chọn bằng cách điều chỉnh cấu trúc hoặc tinh chỉnh tham số, nhằm đạt kết quả vượt trội hơn so với mô hình gốc, với mục tiêu định hướng: đạt weighted F1 $\geq 90\%$ trên tập kiểm thử.

2.3.2.4 Phương pháp đánh giá hệ thống

Đánh giá hiệu quả của hệ thống thông qua các chỉ số chuẩn như độ chính xác (accuracy), độ nhạy (precision), độ bao phủ (recall), và F1-score, so sánh với phương pháp thủ công để làm rõ ưu điểm. Đồng thời, đo lường tốc độ phân loại (thời gian xử lý) và tỷ lệ lỗi trong điều kiện thực tế, từ đó xác định mức độ thành công và khả năng ứng dụng thực tiễn của hệ thống.

Trong các chỉ số đánh giá, **Recall** đối với lớp “tỏi hư” và **F1-Score** sẽ là các chỉ số được ưu tiên hàng đầu, vì mục tiêu cốt lõi là tối thiểu hóa việc bỏ sót sản phẩm không đạt chất lượng.

3. TỔNG QUAN VỀ LĨNH VỰC NGHIÊN CỨU

3.1 Các phương pháp phát hiện và phân loại nông sản sau thu hoạch

3.1.1 Phương pháp truyền thống

Trong quá trình phân loại nông sản sau thu hoạch (như tỏi), phương pháp truyền thống chủ yếu dựa vào sự quan sát thủ công của công nhân. Việc phân loại được thực hiện thông qua mắt thường. Tuy nhiên, cách làm này gặp nhiều hạn chế: phụ thuộc vào kinh nghiệm cá nhân, dễ xảy ra sai sót, hiệu suất thấp và không thể áp dụng cho dây chuyền tự động hoá quy mô lớn. Đặc biệt, với những sản phẩm như tỏi, việc nhận diện tỏi hư, tỏi còn vỏ hay tỏi sạch bằng mắt thường có thể không chính xác cao nhất.

3.1.2 Phương pháp sử dụng mô hình học sâu (Deep Learning)

Mô hình học sâu (Deep learning), đặc biệt là mạng nơ-ron tích chập (CNN), đang trở thành xu hướng mới trong lĩnh vực phân loại hình ảnh nông sản. CNN có khả năng tự

động trích xuất đặc trưng từ ảnh, giảm thiểu tối đa sự can thiệp thủ công và cho kết quả chính xác cao. Đối với bài toán phân loại tỏi, mạng CNN có thể học và nhận diện các đặc trưng về màu sắc, cấu trúc bề mặt, tình trạng lớp vỏ... để phân biệt giữa tỏi hư, tỏi sạch, và tỏi còn vỏ.

Một số mô hình mạng học sâu phổ biến như ResNet50, VGG16, MobileNetV2, EfficientNet-B0, và InceptionV3, Vision Transformer và Swin Transformer được sử dụng rộng rãi trong các bài toán phân loại ảnh thực phẩm và nông sản, đặc biệt khi kết hợp với học chuyển giao (Transfer Learning) để tận dụng sức mạnh từ các mô hình đã huấn luyện trước trên các tập dữ liệu lớn.

3.2 Các nghiên cứu liên quan

Tự động hóa quy trình phân loại nông sản, đặc biệt là tỏi, đang là xu hướng nghiên cứu mạnh mẽ nhằm thay thế phương pháp thủ công tốn kém và thiếu nhất quán. Các nghiên cứu gần đây tập trung vào hai hướng chính:

- Tối ưu hóa các mô hình CNN nhẹ (Lightweight CNN) để phát hiện lỗi cụ thể trên củ tỏi
- Ứng dụng kiến trúc Transformer để nâng cao độ chính xác tổng thể trong môi trường phức tạp.

3.2.1 Ứng dụng CNN và hệ thống thị giác máy trong phát hiện lỗi tỏi

Đối với bài toán phát hiện hư hỏng vật lý (damage detection), các mô hình phát hiện vật thể tốc độ cao đang cho thấy hiệu quả vượt trội. Điển hình là nghiên cứu của Zhang và cộng sự (2026) với mô hình Garlic-YOLO-DD. Nhóm tác giả đã đề xuất một kiến trúc nhẹ dựa trên YOLO, tích hợp cơ chế chú ý SimAM để nhận diện các vết hư hỏng nhỏ trên bề mặt tỏi với độ chính xác mAP@50 đạt hơn 27% so với mô hình gốc, đồng thời giảm đáng kể chi phí tính toán để phù hợp với các thiết bị biên tại xưởng [2].

Bên cạnh việc phát hiện hư hỏng, bài toán phân loại tỏi "còn vỏ" (skinned/unpeeled) cũng được giải quyết hiệu quả bằng thị giác máy tính. Wang và cộng sự (2025) đã phát triển một hệ thống robot thông minh tích hợp camera quan sát, có khả năng tự động nhận diện và loại bỏ tỏi chưa bóc sạch vỏ trên băng chuyền. Hệ thống này đạt tỷ lệ nhận diện thành công lên tới 99.15%, chứng minh tính khả thi của việc áp dụng AI vào dây chuyền chế biến tỏi sau thu hoạch [3].

3.2.2 Ứng dụng Vision Transformer (ViT) trong đánh giá chất lượng nông sản

Trong khi CNN chiếm ưu thế về tốc độ, kiến trúc Vision Transformer (ViT) đang nổi lên như một giải pháp mới cho các bài toán phân loại độ tươi và chất lượng đòi hỏi trích xuất đặc trưng toàn cục. Nghiên cứu của Chen và cộng sự (2025) về mô hình Multi-Task NoisyViT đã chứng minh khả năng vượt trội của Transformer so với CNN truyền thống trong việc đánh giá độ tươi của rau củ quả, đạt độ chính xác trên 99% nhờ khả năng học các mối quan hệ ngữ cảnh phức tạp trong ảnh [4].

Những kết quả này đặt nền tảng vững chắc cho đề tài nghiên cứu, khẳng định hướng đi kết hợp giữa các mô hình học sâu hiện đại (như ResNet, EfficientNet và Swin Transformer) cùng các cơ chế chú ý (Attention) là hoàn toàn phù hợp và cấp thiết để giải quyết toàn diện bài toán phân loại chất lượng tòi (sạch, hư, còn vỏ) hiện nay.

3.3 Các kỹ thuật chính được sử dụng

Để giải quyết bài toán phân loại chất lượng tòi, đề tài đã áp dụng và kết hợp một loạt các công nghệ và phương pháp tiên tiến trong lĩnh vực học sâu và thị giác máy tính. Các phương pháp này được lựa chọn nhằm tối ưu hóa độ chính xác, hiệu suất và khả năng tổng quát hóa của mô hình.

3.3.1 Học Chuyển giao (Transfer Learning)

Đây là phương pháp cốt lõi của nghiên cứu. Thay vì xây dựng một mô hình từ đầu, đề tài tận dụng kiến thức đã được huấn luyện trước từ các mô hình lớn trên tập dữ liệu khổng lồ (như ImageNet). Cách tiếp cận này giúp:

- Tiết kiệm thời gian và tài nguyên tính toán đáng kể.
- Tăng độ chính xác do mô hình đã học được các đặc trưng cơ bản và phức tạp.

Các kiến trúc mô hình nền tảng được khảo sát bao gồm: (ResNet50, VGG16, MobileNetV2, EfficientNet-B0, và InceptionV3, Vision Transformer (ViT) và Swin Transformer (Swin-T))

3.3.2 Các Kỹ thuật Huấn luyện và Tối ưu hóa

Một tập hợp các kỹ thuật hiện đại được sử dụng để cải thiện quá trình huấn luyện và nâng cao hiệu suất của mô hình:

- Tăng cường dữ liệu (Data Augmentation): Tự động tạo ra các biến thể mới từ dữ liệu gốc (xoay, lật, thu phóng, chỉnh sáng) để làm đa dạng tập huấn luyện, giúp mô hình có khả năng nhận diện tốt ở nhiều điều kiện khác nhau.
- Cân bằng trọng số lớp (Class Weights Balancing): Giải quyết vấn đề chênh lệch dữ liệu giữa các lớp (ví dụ: số ảnh tử sạch nhiều hơn tử hư).
- Tinh chỉnh (Fine-Tuning): Một chiến lược của học chuyển giao, trong đó chỉ một phần nhỏ các lớp cuối của mô hình được "mở băng" để cập nhật trọng số.
- Kỹ thuật chống quá khớp (Regularization): Sử dụng Dropout, một kỹ thuật vô hiệu hóa ngẫu nhiên một số nơ-ron trong quá trình huấn luyện, buộc mô hình phải học các đặc trưng một cách bền vững hơn.
- Lập lịch tốc độ học (Learning Rate Scheduling): Áp dụng Cosine Decay để tự động điều chỉnh tốc độ học, giúp mô hình hội tụ nhanh ở giai đoạn đầu và tinh chỉnh chính xác ở giai đoạn sau.
- Dừng sớm (Early Stopping): Theo dõi hiệu suất trên tập dữ liệu kiểm thử và tự động kết thúc quá trình huấn luyện khi không còn sự cải thiện, giúp tiết kiệm thời gian và chọn ra mô hình tốt nhất.

3.3.3 Cơ chế Chú ý

Để nâng cao hơn nữa khả năng trích xuất đặc trưng, mô hình tốt nhất được tích hợp thêm các mô-đun chú ý. Cơ chế này cho phép mô hình "tập trung" vào những vùng thông tin quan trọng nhất trong ảnh (ví dụ: vùng bị hỏng trên củ tỏi) và bỏ qua các vùng không liên quan. Các cơ chế được thử nghiệm bao gồm: **SE (Squeeze-and-Excitation)**, **CBAM**, **SimAM**, và **Coordinate Attention (CoordAtt)**.

4. TIẾN ĐỘ THỰC HIỆN

Bảng 1: Tiến độ thực hiện của luận văn

Tháng	1	2	3	4	5	6
Dự kiến nội dung thực hiện						
Tiếp nhận đề án						
Nghiên cứu tổng quan, lý thuyết, thu thập dữ liệu						

Thực nghiệm, cải tiến mô hình						
Đánh giá kết quả						
Viết đề án						

5. BỐ CỤC DỰ KIẾN CỦA LUẬN VĂN

Bố cục dự kiến của luận văn gồm 5 chương

Chương 1. TỔNG QUAN NGHIÊN CỨU

1.1 Tính cấp thiết của đề tài

1.2 Mục tiêu nghiên cứu

1.3 Đối tượng, phạm vi nghiên cứu

1.4 Phương pháp nghiên cứu

1.5 Cấu trúc luận văn

TÓM TẮT CHƯƠNG 1

Chương 2. CƠ SỞ LÝ THUYẾT VÀ MÔ HÌNH NGHIÊN CỨU

2.1 Cơ sở lý thuyết

2.2 Tổng quan các nghiên cứu có liên quan và đề xuất mô hình nghiên cứu

2.2.1 Nghiên cứu nước ngoài

2.2.2. Nghiên cứu trong nước

2.3 Mô hình nghiên cứu và các giả thuyết

TÓM TẮT CHƯƠNG 2

Chương 3. PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Thiết kế nghiên cứu

3.1.1 Quy trình nghiên cứu

3.1.2 Nghiên cứu định tính, định lượng

3.1.3 Phương pháp thu thập dữ liệu hình ảnh

3.2 Xử lý và chuẩn bị dữ liệu

3.2.1 Tiền xử lý ảnh và gán nhãn dữ liệu

3.2.2 Phân chia tập dữ liệu huấn luyện

3.3 Xây dựng và huấn luyện mô hình

3.3.1 Lựa chọn kiến trúc mô hình học sâu

3.3.2 Cấu hình tham số huấn luyện

3.3.3 Cải thiện và tối ưu hóa mô hình

TÓM TẮT CHƯƠNG 3

Chương 4. KẾT QUẢ NGHIÊN CỨU

4.1 Mô tả mẫu

4.2 Trình bày kết quả nghiên cứu

TÓM TẮT CHƯƠNG 4

Chương 5. HÀM Ý QUẢN TRỊ VÀ KIẾN NGHỊ

TÓM TẮT CHƯƠNG 5

KẾT LUẬN TOÀN BỘ LUẬN VĂN

TÀI LIỆU THAM KHẢO PHỤ LỤC

6. TÀI LIỆU THAM KHẢO

- [1] Chính phủ, "Báo cáo tình hình kinh tế - xã hội quý IV và năm 2025," Cổng Thông tin điện tử Chính phủ, 08 01 2026. <https://xaydungchinhhsach.chinhphu.vn/bao-cao-tinh-hinh-kinh-te-xa-hoi-quy-iv-va-nam-2025-119260105155650719.htm>
- [2] Y. Gao, X. Ma, Z. Xia, T. Qi, X. Wang, Z. He, and G. Chen, "Garlic-YOLO-DD: A lightweight object detection algorithm for garlic damage detection," *Frontiers in Plant Science*, vol. 16, Art. no. 1702045, Jan. 2026, <https://doi.org/10.3389/fpls.2025.1702045>.
- [3] Z. Zhu, X. Cao, Y. Xiao, L. Xin, L. Xin, and S. Li, "Intelligent detection and automatic removal robot for skinned garlic cloves," *Agriculture*, vol. 15, no. 10, p. 1076, Oct. 2025, <https://doi.org/10.3390/agriculture15101076>.
- [4] S. Esfandiari Fard, T. Ghosh, and E. Sazonov, "Multi-Task NoisyViT for Enhanced Fruit and Vegetable Freshness Detection and Type Classification," *Sensors*, vol. 25, no. 19, p. 5955, Sep. 2025, <https://doi.org/10.3390/s25195955>.
- [5] A. Bhargava and A. Bansal, "Fruits and vegetables quality evaluation using computer vision: A review," *Journal of King Saud University - Computer and Information Sciences*, vol. 33, no. 3, pp. 243–257, Mar. 2021, <https://doi.org/10.1016/j.jksuci.2018.06.002>.
- [6] K. Shaheed, I. Qureshi, F. Abbas, S. Jabbar, Q. Abbas, H. Ahmad, and M. Z. Sajid, "EfficientRMT-Net—An efficient ResNet-50 and vision transformers approach for classifying potato plant leaf diseases," *Sensors*, vol. 23, no. 23, p. 9516, Nov. 2023, <https://doi.org/10.3390/s23239516>.
- [7] M. I. Hossen, M. Awrangjeb, S. Pan, and A. A. Mamun, "Transfer learning in agriculture: A review," *Artificial Intelligence Review*, vol. 58, Art. no. 97, Jan. 2025, <https://doi.org/10.1007/s10462-024-11081-x>.

- [8] T. Cao and H. Okamoto, "Defect detection and size grading of harvested Japanese yam using computer vision technology," *Academic Journal of Agriculture & Life Sciences*, vol. 4, no. 1, pp. 30–42, 2023, <https://doi.org/10.25236/AJALS.2023.040106>.
- [9] W. Liu and A. Zhang, "Plant disease detection algorithm based on efficient Swin transformer," *Computers, Materials & Continua*, vol. 82, no. 2, pp. 3045–3068, Feb. 2025, <https://doi.org/10.32604/cmc.2024.058640>.
- [10] M. R. Tonmoy, M. M. Hossain, and N. Dey, "MobilePlantViT: A mobile-friendly hybrid vision transformer for generalized plant disease image classification," *arXiv preprint arXiv:2503.16628*, Mar. 2025. <https://arxiv.org/abs/2503.16628>
- [11] D. Q. Thuyet, Y. Kobayashi, and M. Matsuo, "A robot system equipped with deep convolutional neural network for autonomous grading and sorting of root-trimmed garlicks," *Computers and Electronics in Agriculture*, vol. 178, p. 105727, Nov. 2020, <https://doi.org/10.1016/j.compag.2020.105727>.